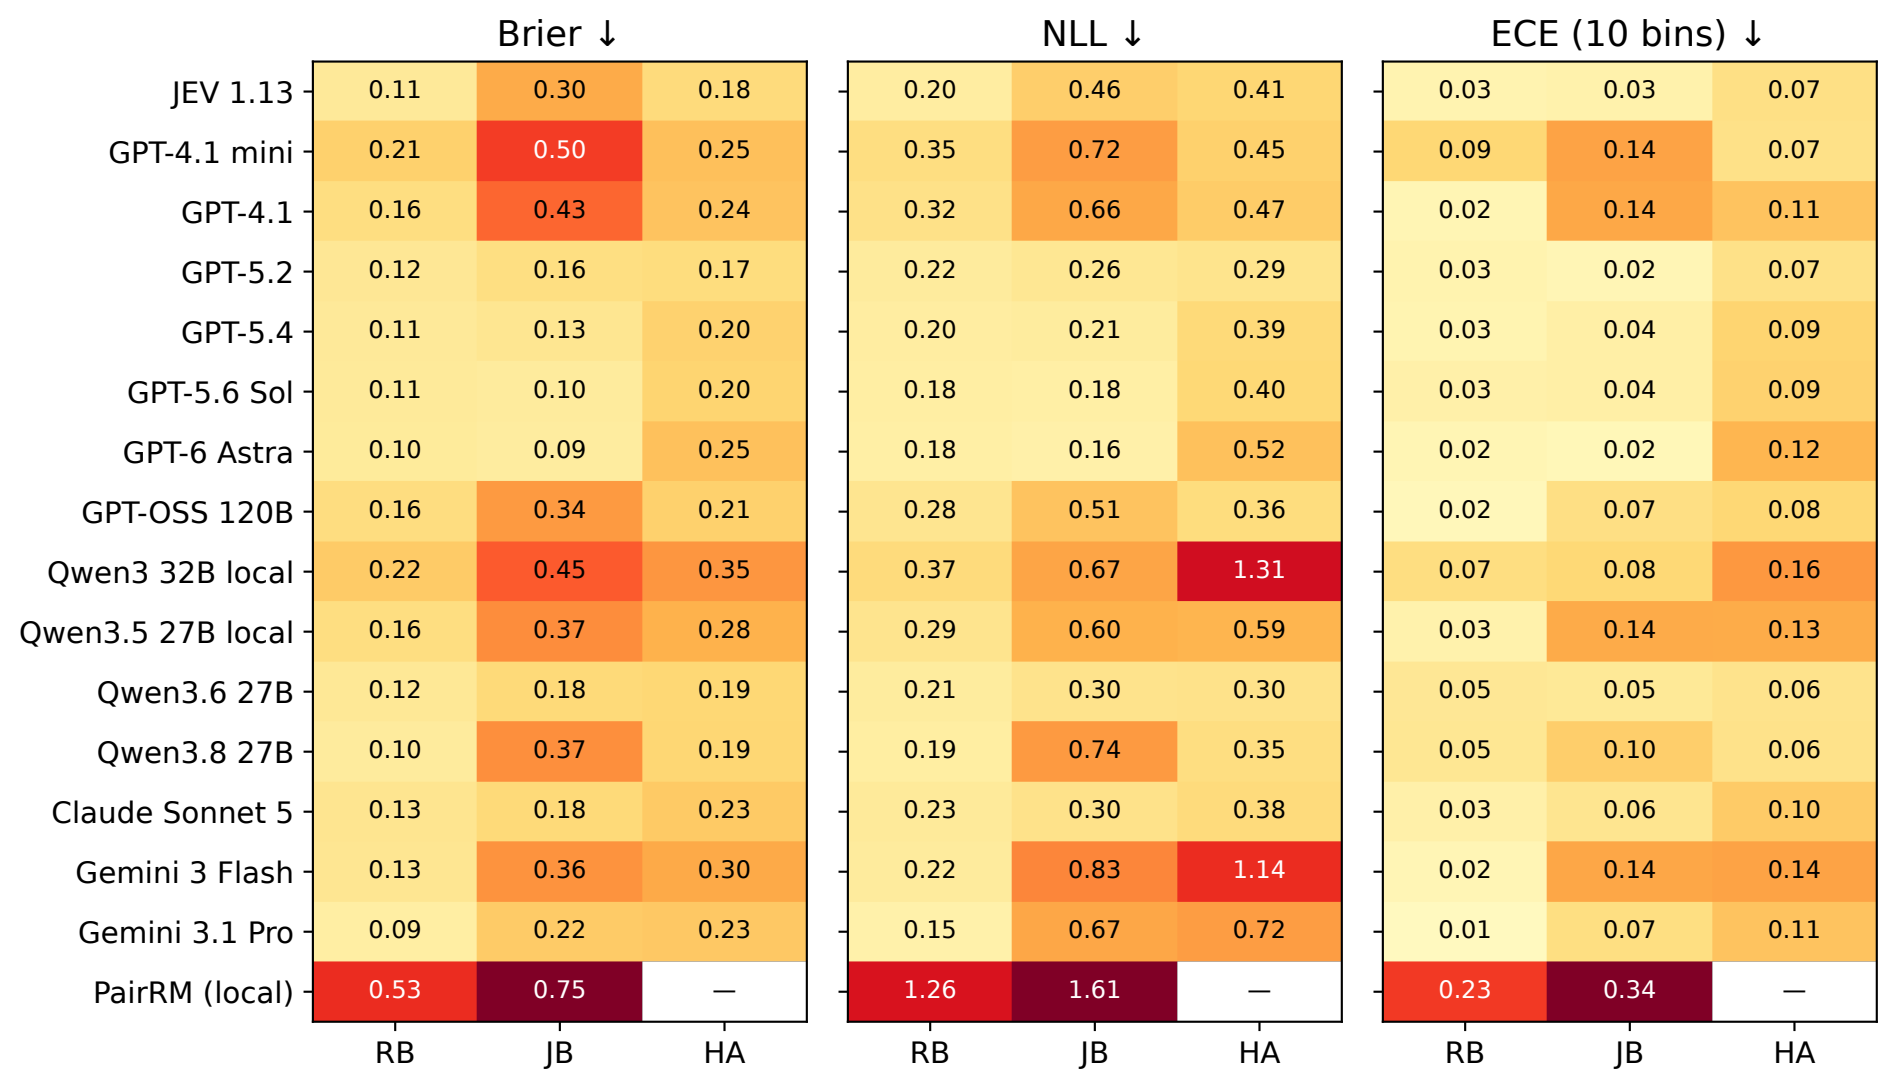
Brier ↓
NLL ↓
ECE (10 bins) ↓
JEV 1.13 0.11 0.30 0.18 0.20 0.46 0.41 0.03 0.03 0.07
GPT-4.1 mini 0.21 0.50 0.25 0.35 0.72 0.45 0.09 0.14 0.07
GPT-4.1 0.16 0.43 0.24 0.32 0.66 0.47 0.02 0.14 0.11
GPT-5.2 0.12 0.16 0.17 0.22 0.26 0.29 0.03 0.02 0.07
GPT-5.4 0.11 0.13 0.20 0.20 0.21 0.39 0.03 0.04 0.09
GPT-5.6 Sol 0.11 0.10 0.20 0.18 0.18 0.40 0.03 0.04 0.09
GPT-6 Astra 0.10 0.09 0.25 0.18 0.16 0.52 0.02 0.02 0.12
GPT-OSS 120B 0.16 0.34 0.21 0.28 0.51 0.36 0.02 0.07 0.08
Qwen3 32B local 0.22 0.45 0.35 0.37 0.67 1.31 0.07 0.08 0.16
Qwen3.5 27B local 0.16 0.37 0.28 0.29 0.60 0.59 0.03 0.14 0.13
Qwen3.6 27B 0.12 0.18 0.19 0.21 0.30 0.30 0.05 0.05 0.06
Qwen3.8 27B 0.10 0.37 0.19 0.19 0.74 0.35 0.05 0.10 0.06
Claude Sonnet 5 0.13 0.18 0.23 0.23 0.30 0.38 0.03 0.06 0.10
Gemini 3 Flash 0.13 0.36 0.30 0.22 0.83 1.14 0.02 0.14 0.14
Gemini 3.1 Pro 0.09 0.22 0.23 0.15 0.67 0.72 0.01 0.07 0.11
PairRM (local) 0.53 0.75 — 1.26 1.61 — 0.23 0.34 —
RB JB HA RB JB HA RB JB HA